

Utsav Pandey

✉ utsav.pandey18@gmail.com

☎ 0780725040

📍 Paris, France

🌐 [linkedin.com/in/utsavpandey](https://www.linkedin.com/in/utsavpandey)

🐙 github.com/utsavosho

PROFIL

Data Engineer avec 4 ans d'expérience dans la conception et l'exploitation de pipelines de données end-to-end pour de grands retailers français. Spécialisé dans l'ingestion de données à grande échelle, le traitement distribué avec PySpark, l'orchestration des pipelines avec Airflow, et le développement de modèles dbt pour la transformation et la modélisation des données dans Snowflake. Solide expertise Python et SQL couvrant l'ensemble du cycle de vie de la donnée, de l'ingestion brute au traitement distribué et aux tables analytiques en production. Expérience de la mise à disposition des données pour la BI avec PowerBI et de leur intégration marketplace via Mirakl.

EXPÉRIENCE PROFESSIONNELLE

Data Engineer

09/2022 – Present | Paris, France

- Nricher*
- Plateforme SaaS d'enrichissement de données produits et d'intelligence compétitive pour 8+ grands retailers français : Castorama, Fnac, Carrefour, La Redoute, Conforama, Vente Unique, MadeInDesign, Nedgis.
 - Conception et maintenance de pipelines d'ingestion à grande échelle traitant les catalogues produits provenant de 20+ sources e-commerce, avec gestion des proxies et rotation des requêtes pour garantir la disponibilité des flux.
 - Mise en place de traitements distribués avec PySpark pour le prétraitement de volumes importants de données produits : parsing de données semi-structurées, nettoyage, normalisation, déduplication et jointures multi-sources.
 - Développement de pipelines Python et PySpark pour le traitement et l'enrichissement des titres, descriptions, attributs techniques et métadonnées images des produits.
 - Développement et maintenance de modèles dbt dans Snowflake pour la transformation, la validation, la normalisation et la modélisation des données produits après ingestion et prétraitement.
 - Conception et optimisation de l'architecture du data warehouse Snowflake : procédures stockées, stages externes et structures de tables optimisées pour des charges analytiques multi-clients.
 - Orchestration end-to-end avec Apache Airflow, de l'ingestion des données jusqu'au traitement PySpark, au chargement dans Snowflake et à l'exécution des transformations dbt.
 - Mise à disposition des données analytiques dans Power BI pour le suivi des performances produits, des prix et des indicateurs métier.
 - Livraison des données enrichies via Mirakl pour la génération automatique de fiches articles et la publication dans les catalogues produits des retailers.
 - Gestion de 8+ environnements de production multi-clients, avec isolation des configurations, supervision des pipelines et maintien en conditions opérationnelles.

Data Analyst

08/2019 – 07/2021 | Hyderabad, Inde

- Cognizant*
- Conception de workflows SQL et Python (Pandas) pour le traitement et l'analyse de larges volumes de données, avec alimentation de dashboards Power BI et automatisation des reportings métier.
 - Conception et suivi de KPIs opérationnels dans Power BI, fournissant aux équipes métier et projet une visibilité sur les performances et les tendances clés.
 - Optimisation des requêtes SQL et automatisation des traitements afin d'améliorer les performances et la fiabilité des analyses.

Data Analyst

04/2018 – 05/2019 | Hyderabad, Inde

- Tech Mahindra*
- Automatisation de pipelines d'extraction, de validation et de reporting de données en SQL et Python, avec alimentation de dashboards Power BI.
 - Contrôle qualité et validation des données avant intégration dans les outils de reporting et mise à disposition dans Power BI.
 - Conception et suivi de reportings et indicateurs dans Power BI pour faciliter le suivi des performances opérationnelles.

FORMATION

EPITA - École pour l'informatique et les techniques avancées

09/2021 – 08/2022 | Paris, France

Master of Science in Computer Science – Data Science & Analytics

Chhattisgarh Swami Vivekanand Technical University

08/2012 – 08/2016 | Bhilai, Inde

License Informatique, BSc. Computer Science

COMPÉTENCES

Langages

Python, SQL, Java, Typescript, Javascript

Data Visualisation

Powerbi, Metabase, Tableau

Cloud & Stockage

Azure, Azure Blob Storage, Docker

Marketplace

Mirakl

Data Transformation

DBT, Spark, Pyspark

Data Integration

Airbyte

Data Engineering

Snowflake (Data Warehouse), Terraform, Pipelines ETL / ELT, Ingestion de données, Transformation de données, Modélisation de données, Orchestration de workflows

Frameworks & Bibliothèques

Apache Airflow, Spark, PySpark, DBT Core, DBT Cloud, Scrapy, Pandas, Kafka, Airbyte

Data Warehousing

Snowflake, PostgreSQL

Outils

Git, GitHub, CI / CD, Linux, VS Code, Spyder, Pycharm, Claude code

Data Streaming

Apache Kafka